

Relatório: Trabalho Prático 2

Giovana Lins Cavalcanti, 22352905

I. METODOLOGIA

O Objetivo deste trabalho é quantificar o ganho de especialização e perda de generalização obtidos com o *fine-tuning* de uma LLM para a tarefa Text-to-SQL. Para isso, foi projetado um pipeline de execução com cinco fases: 1) implementação da métrica customizada de *Execution Accuracy*, 2) estabelecimento do baseline de desempenho, 3) execução do *fine-tuning*, 4) avaliação de desempenho na tarefa-alvo e 5) análise quantitativa de regressão de Capacidade. Devido a impossibilidade de execução local, fora utilizado uma sessão da plataforma Kaggle¹ com 2 GPUs T4, cada uma com 15GB de VRAM, adaptando o código conforme o necessário.

A. Implementação da Métrica Customizada de Execution Accuracy

A métrica única e principal do trabalho é a *Execution Accuracy*, a qual mede a acurácia das saídas do modelo. Se o resultado da execução for idêntico ao resultado da consulta *ground truth* do dataset, a *Execution Accuracy* retorna o valor 1.0, independente da ordem em que as tuplas foram retornadas (exceto se a consulta conter a cláusula “ORDER BY”). Senão, o valor retornado é 0.0.

A implementação dessa métrica se dá em uma classe que herda de *BaseMetric*, classe da framework *DeepEval* para avaliação de LLMs que implementa atributos e métodos básicos para criar métricas customizadas [1]. O método principal dessa classe é o *measure()*, onde foi implementado o cálculo da *Execution Accuracy*: primeiramente, é necessário extrair a consulta SQL bruta da resposta do modelo, já que podem haver textos explicativos ou blocos markdown inclusos. Em seguida, é recuperado o banco de dados SQLite com as tabelas utilizadas pelas consultas para então executá-las. Por fim, são comparados os conjuntos de resultados de forma insensível à ordem das linhas.

B. Estabelecimento do Baseline de Desempenho

Nesta fase, o split de treinamento do dataset Spider [2] é pré-processado para compor um conjunto de mensagens no formato ChatML. As perguntas em linguagem natural são postas como mensagens do tipo “user”, já as consultas em SQL, do tipo “assistant”, objetivando comunicar ao modelo como seriam possíveis perguntas e quais seriam as respostas corretas. Esses dados são usadas para compor exemplos de *few-shot learning* para a tarefa Text-to-SQL e, na próxima fase, serão utilizadas para realizar o *fine-tuning* do modelo.

É pedido que, dado um esquema de banco de dados e uma pergunta em linguagem natural, o modelo formule uma consulta em SQL que responda a pergunta, oferecendo três exemplos distintos. São utilizados os mesmos exemplos, retirados

da etapa de pré-processamento, para cada prompt enviado ao modelo, cuja tarefa-alvo provém da split de desenvolvimento desse mesmo dataset. Assim, os resultados são armazenados para avaliação na quarta fase.

C. Execução do Fine-Tuning

A terceira fase é composta de duas rodadas de *fine-tuning* com a técnica *Low-Rank Adaptation*. O modelo é treinado com as mensagens provenientes do pré-processamento da split de treinamento do spider, diferindo nos hiperparâmetros de treinamento. Essas divergências podem ser vistas na tabela I.

Tabela I
COMPARAÇÃO DE HIPERPARÂMETROS

Hiperparâmetro.	Config A	Config B
learning_rate	2.0×10^{-4}	5.0×10^{-5}
num_train_epochs	1	3
per_device_train_batch_size	4	4
gradient_accumulation_steps	4	4
warmup_ratio	0.03	0.03
lr_scheduler_type	cosine	cosine
max_seq_length	2048	2048

Em suma, o modelo treinado sob a configuração A converge de forma mais lenta que sob a configuração B, mas passa por apenas uma época de treinamento.

D. Avaliação de Desempenho na Tarefa-Alvo

Esta fase consiste na medição da *Execution Accuracy* dos modelos baseline e dos dois modelos *fine-tuned*. Por meio da framework *pytest*², os sucessos e falhas dos modelos são calculados de forma automatizada, possibilitando visualizar os ganhos e perdas obtidos com os diferentes hiperparâmetros *fine-tuning*. Como os três modelos foram submetidos aos mesmos testes, a comparação direta entre os resultados é válida.

E. Análise Quantitativa de Regressão de Capacidade

Por último, os modelo base e *fine-tuned* são submetidos às 150 questões do Massive Multitask Language Understanding (MMLU) [3] [4]. Três categorias de perguntas foram utilizadas: STEM, humanidades e ciências sociais. De cada uma dessas categorias, foram extraídas 50 perguntas de uma base de dados do MMLU atrelada a elas, sendo escolhidas “college_computer_science”, “philosophy” e “high_school_macro_economics”. No total, 150 perguntas foram feitas aos modelos nessa fase.

¹<https://www.kaggle.com/code/giovanal/nlp-tp2>

²<https://pytest.org/>

Ao contrário dos experimentos anteriores, aqui foi utilizada uma abordagem de 5-shot learning, utilizando 5 exemplos de perguntas e respostas antes de passar a questão ao modelo. A métrica nessa fase é a acurácia das respostas, observando quantas questões o modelo baseline respondeu corretamente no total e em cada categoria e comparando com o modelo *fine-tuned*.

II. RESULTADOS

III. DISCUSSÃO

REFERÊNCIAS

- [1] DeepEval, “‘Do it yourself’ metrics,” Disponível em <https://deepeval.com/docs/metrics-custom>, 2026, acesso: 12, Jun, 2026.
- [2] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, and D. Radev, “Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-sql task,” in *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*. Brussels, Belgium: Association for Computational Linguistics, 2018.
- [3] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, “Measuring massive multitask language understanding,” *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.
- [4] D. Hendrycks, C. Burns, S. Basart, A. Critch, J. Li, D. Song, and J. Steinhardt, “Aligning ai with shared human values,” *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.